Практическая работа
Анализ и обработка данных с использованием Pandas и NumPy

Тема: Основы работы с табличными данными, фильтрация, обработка пропущенных значений и статистический анализ.

Цель: Освоить методы Pandas и NumPy для загрузки, исследования, обработки и анализа табличных данных о пассажирах «Титаника».

Исходный набор данных: Titanic dataset (Kaggle) — https://www.kaggle.com/datasets/brendan45774/test-file/data

Перед началом: загрузите CSV-файл, проверьте наличие столбцов Age, Sex, Pclass, Fare, Embarked, Cabin и Survived. Задания о выживаемости выполняются только с файлом, содержащим фактические значения Survived (0 — погиб, 1 — выжил). Если Survived отсутствует, используйте подходящий набор Titanic с этой колонкой, а не придумывайте значения.

Часть I. Знакомство с Pandas

Изучите основные понятия:

1. Series — одномерная структура данных с индексами.
2. DataFrame — двумерная табличная структура из столбцов Series.
3. Индексация — обращение к строкам, столбцам и элементам таблицы.
4. Фильтрация — выбор строк по логическим условиям.
5. Пропущенные значения (NaN) — обнаружение и обработка отсутствующих данных.

Самостоятельно ознакомьтесь со способами создания DataFrame и основными методами Pandas.

Часть II. Загрузка и первичный анализ данных

6. Загрузите CSV-файл в DataFrame.
7. Выведите первые n строк таблицы, где n вводится пользователем.
8. Выведите последние 5 строк.
9. Определите общее количество строк и столбцов.
10. Выведите названия всех столбцов.
11. Определите типы данных каждого столбца.
12. Разделите признаки на числовые и категориальные по смыслу данных.
13. Выведите среднее, медиану, минимум, максимум и стандартное отклонение числовых признаков.
14. Определите количество пассажиров каждого класса (Pclass).
15. Определите количество уникальных значений в Embarked.

Контрольный вопрос. Почему Pclass, содержащий целые числа, следует рассматривать как категориальный признак?

Часть III. Обработка пропущенных значений

16. Определите количество пропусков в каждом столбце.
17. Вычислите процент пропусков относительно общего числа строк.

18. Определите столбец с максимальным количеством пропусков.
19. До заполнения пропусков рассчитайте для Age среднее, медиану, минимум, максимум, стандартное отклонение и количество известных значений.
20. Заполните пропуски в Age медианой, рассчитанной по исходным известным возрастам.
21. После заполнения Age повторно рассчитайте все шесть характеристик.
22. Представьте сравнение «до / после» в таблице ниже.
23. Удалите строки с отсутствующим Embarked.
24. Определите долю пропусков в Cabin; если она превышает 50%, удалите этот столбец.
25. Проверьте, какие пропуски остались после обработки.
26. Сравните количество строк и столбцов до и после обработки.

Показатель	До обработки	После обработки
Среднее арифметическое		
Медиана		
Минимальный возраст		
Максимальный возраст		
Стандартное отклонение		
Количество известных значений		

Контрольные вопросы:

27. Почему медиана может быть предпочтительнее среднего для заполнения пропусков?
28. Какие характеристики изменились после заполнения, а какие остались неизменными?
29. Почему после заполнения может измениться стандартное отклонение?
30. Сохраняется ли исходное распределение возрастов после заполнения медианой? Обоснуйте.

Часть IV. Анализ данных с помощью NumPy

Выполните вычисления с использованием NumPy. При необходимости преобразуйте столбцы DataFrame в массивы NumPy.

31. Рассчитайте общий процент выживших.
32. Вычислите процент выживших отдельно среди мужчин и женщин.
33. Определите средний возраст мужчин и женщин.
34. Рассчитайте средний возраст выживших и погибших отдельно для мужчин и женщин.
35. Определите минимальную, максимальную и среднюю стоимость билета.
36. Рассчитайте стандартное отклонение возраста.

Результаты сравнительного анализа представьте в виде таблицы.

Контрольный вопрос. Какие различия между мужчинами и женщинами обнаружены по рассчитанным показателям?

Часть V. Фильтрация данных

Задание 1. Отберите мужчин старше 30 лет, путешествовавших первым классом. Выведите число пассажиров и первые 10 строк результата.

Задание 2. Отберите пассажиров моложе 18 лет или женщин, которые при этом выжили. Определите количество.

Задание 3. Найдите пассажиров третьего класса, стоимость билета которых выше средней стоимости билета в этом классе.

Задание 4. Отберите пассажиров от 20 до 40 лет включительно, отправившихся из порта S (Southampton).

Контрольный вопрос. Чем отличается сочетание условий через логические «И» и «ИЛИ» при фильтрации DataFrame?

Часть VI. Группировка и агрегирование

37. Сгруппируйте данные по классу (Pclass) и полу (Sex). Для каждой группы вычислите количество пассажиров, средний возраст, долю выживших (%) и среднюю стоимость билета.
38. Сгруппируйте данные по порту посадки (Embarked). Вычислите количество пассажиров и процент выживших по каждому порту.
39. Определите класс пассажиров с наибольшей долей выживших.

Контрольный вопрос. Чем группировка отличается от фильтрации?

Часть VII. Сохранение результатов

40. Сохраните обработанный DataFrame в titanic_processed.csv.
41. Сохраните результаты группировки по классу и полу в titanic_statistics.csv.
42. Повторно загрузите обработанный CSV и убедитесь, что данные сохранились корректно.

Часть VIII. Выводы по работе

Сформулируйте краткие выводы по следующим вопросам:

43. Какие признаки содержали наибольшее количество пропусков?
44. Как обработка пропусков повлияла на размер данных и статистику возраста?
45. Как различалась выживаемость мужчин и женщин?
46. В каком классе наблюдалась наибольшая доля выживших?
47. Какие возможности Pandas и NumPy оказались наиболее полезными?

Требования к результату

48. Python-файл (.py) или Jupyter Notebook (.ipynb) с выполненными заданиями.
49. Обработанный файл titanic_processed.csv.
50. Файл группировки titanic_statistics.csv.
51. Краткие выводы и заполненная таблица сравнения возраста до и после обработки.

Примечание: Для каждого этапа выведите результат выполнения. Готовые решения в условиях задания не приводятся.